

NAMA : YUWAN VIRA ANTIKA RINI

NRP : 5049231044


Tugas Tambahan: Implementasi, Audit, dan Penalaran Klinis dalam Big Data Kesehatan

Bagian 1: Analisis Skenario Konflik Replikasi

1. Tiga Titik Kritis "Diskresi Peneliti" dalam Pipeline Big Data

Dalam skenario prediksi risiko sepsis, perbedaan hasil antara Tim A dan Tim B dari dataset yang sama kemungkinan besar terjadi karena adanya perbedaan keputusan subjektif (diskresi peneliti) pada saat menyiapkan data. Tiga titik kritis yang biasanya membuat hasilnya berbeda adalah:

- **Penentuan Kriteria Sampel (*Cohort Selection*):** Setiap tim sering kali mempunyai standar yang berbeda soal data pasien mana yang layak dipakai. Misalnya, Tim A memutuskan untuk membuang data pasien yang memiliki penyakit penyerta lain (seperti riwayat gagal ginjal atau diabetes) agar fokus ke pasien umum, sedangkan Tim B tetap memasukkan semua pasien. Perbedaan pemilihan ini otomatis membuat karakteristik populasi yang dianalisis menjadi berbeda sejak awal.
- **Cara Menangani Data Kosong (*Missing Values*):** Data Rekam Medis Elektronik (EHR) jarang sekali ada yang 100% lengkap. Kalau ada rekam medis yang datanya bolong, peneliti harus memilih apakah data pasien itu dihapus saja secara keseluruhan, atau diisi menggunakan metode tebakan statistik (imputasi). Perbedaan metode *cleaning* ini akan mengubah bentuk distribusi datanya.
- **Penanganan Angka Ekstrem (*Outlier Klinis*):** Terkadang ada angka yang sangat tinggi atau rendah di rekam medis, misalnya detak jantung di atas 150 bpm. Tim A mungkin berpikir itu hanya *error* dari alat sensor EKG lalu menghapus nilainya, sementara Tim B menganggap itu tanda klinis asli kalau pasien sedang mengalami syok septik. Perbedaan persepsi medis ini akan mengubah pola prediksi algoritma secara drastis.



Gambar 1.1 Ilustrasi perbedaan seleksi kriteria sampel

2. Standard Operating Procedure (SOP) Transparansi Keputusan Analitis

Untuk mencegah gagal replikasi antar-tim, penelitian data kesehatan perlu menerapkan SOP sebagai berikut:

1. **Membuat Rencana Analisis di Awal:** Sebelum mulai mengolah data, tim harus sudah menyepakati dan menulis detail *analysis plan* (seperti kriteria inklusi pasien dan metode penanganan data kosong) supaya langkah kerjanya terarah.
2. **Wajib Memberi Penjelasan di Kodingan:** Setiap kali tim mengubah, menormalisasi, atau menghapus sebuah variabel, mereka wajib menulis alasan medisnya langsung di dalam skrip kode sebagai komentar. Jadi, peneliti lain paham mengapa variabel tersebut dimanipulasi.
3. **Menyusun Kamus Data (*Data Dictionary*):** Wajib membuat satu dokumen yang menjelaskan setiap variabel secara detail beserta satuannya (misalnya: variabel suhu harus jelas apakah memakai Celcius atau Fahrenheit) agar tidak ada salah interpretasi antar-tim.
4. **Menggunakan Version Control:** Semua skrip analisis wajib dikelola menggunakan sistem pelacak seperti Git. Hal ini sangat penting agar tim bisa melacak kapan kode diubah, apa saja yang direvisi, dan meminimalisir risiko kodenya tertimpa secara tidak sengaja.
5. **Peer Code Review:** Sebelum hasil pemodelannya diambil sebagai kesimpulan medis, alur kodingan tersebut harus dicek ulang secara silang oleh anggota tim lain untuk memastikan logika statistiknya sudah benar dan tidak ada bias dari penulis kode pertama.

Bagian 2: Refactoring Pipeline dan Audit Git

Pada bagian ini, simulasi *data wrangling* dan pemodelan prediksi risiko sepsis telah dilakukan menggunakan R Studio. Seluruh proses pengerjaan, mulai dari penyiapan data, penulisan skrip awal, proses perbaikan kode, hingga dokumentasi akhirnya, telah diunggah dan dilacak secara transparan menggunakan sistem kontrol versi Git.

Berikut adalah rincian tahapan yang telah didokumentasikan pada repositori:

1. **Penyiapan Dataset Input (Data Mentah):** Sebelum masuk ke tahap pemrosesan, simulasi ini menggunakan sampel dataset *dummy* yang merepresentasikan data Rekam Medis Elektronik (EHR) dari pasien di ruang ICU. Dataset mentah ini terdiri dari variabel klinis dasar seperti denyut jantung (hr), tekanan darah sistolik (sbp), suhu tubuh (temp), serta label diagnosis akhir (sepsis).

hr	sbp	temp	sepsis
110	95	38.5	1
85	120	36.8	0
125	90	39.2	1
75	115	37.1	0
105	100	38.1	1

Gambar 2.1 Wujud dataset mentah EHR sebelum dilakukan *preprocessing*

2. **Tahap 1 (Commit Pertama):** Mengunggah skrip awal yang sengaja ditulis dengan kualitas buruk untuk menyimulasikan diskresi peneliti yang tidak standar. Skrip ini menggunakan perulangan (*for loop*) yang lambat, penamaan variabel yang tidak intuitif (seperti x1, x2), dan sama sekali tidak memiliki komentar penjelasan.

```
setwd("C:/Users/yuwan vira/OneDrive/Dokumen/BIG DATA")
d <- read.csv("data_final_beneran.csv")
d <- d[complete.cases(d), ]

d$x1 <- d$hr
d$x2 <- d$sbp
d$x3 <- d$temp
d$y <- d$sepsis
```

```

d$x2_norm <- (d$x2 - min(d$x2)) / (max(d$x2) - min(d$x2))

d$f <- 0
for(i in 1:nrow(d)) {
  if(d$x3[i] > 38.0) {
    d$f[i] <- 1
  } else {
    d$f[i] <- 0
  }
}

mod <- glm(y ~ x1 + x2_norm + f, data = d, family = "binomial")
res <- predict(mod, type="response")

d$pred <- 0
for(i in 1:nrow(d)){
  if(res[i] > 0.65){
    d$pred[i] <- 1
  }
}
write.csv(d, "hasil.csv")

```

Gambar 2.2 Skrip awal dengan kualitas rendah sebelum proses refactoring

Skrip awal pada **Gambar 2.2** sengaja ditulis dengan pendekatan konvensional yang buruk untuk merepresentasikan minimnya reproduksibilitas. Rincian letak kesalahannya meliputi:

- **Pembersihan Data yang Tidak Terdokumentasi:** Pada baris awal, skrip menggunakan perintah `d[complete.cases(d), ]` untuk menghapus semua baris rekam medis yang datanya bolong/kosong. Kesalahannya adalah tidak ada komentar yang menjelaskan alasan medis mengapa data tersebut langsung dibuang, bukan diimputasi.
- **Penamaan Variabel yang Ambigu:** Variabel klinis yang krusial sengaja disamarkan menjadi nama yang tidak intuitif, seperti `x1` (*heart rate*), `x2` (*systolic blood pressure*), dan `x3` (suhu tubuh). Dalam ranah medis, menyembunyikan identitas variabel seperti ini sangat berbahaya karena memicu salah interpretasi saat kode dibaca oleh peneliti lain.
- **Penggunaan For-Loop yang Tidak Efisien:** Untuk membuat kategori demam (`suhu > 38.0`) dan kategori prediksi akhir (`skor > 0.65`), kode ini menggunakan perulangan `for (i in 1:nrow(d))`. Dalam konteks Big Data kesehatan yang jumlah barisnya bisa mencapai jutaan, penggunaan fungsi ini sangat lambat, memakan memori besar, dan tidak efisien dibandingkan fungsi vektorisasi.

- **Ketiadaan Rasionalisasi Klinis (Kotak Hitam):** Skrip ini sama sekali tidak menggunakan komentar (tanda #). Dokter atau auditor tidak akan tahu mengapa angka 38.0 dipilih sebagai batas indikator demam, dan mengapa angka 0.65 (bukan 0.5) dipakai sebagai batas *threshold* penentuan risiko sepsis.
- **Output Data yang Membingungkan:** Eksekusi skrip ini menghasilkan *output* hasil.csv yang dipenuhi kolom duplikat dengan nama yang ambigu (x1, f, pred). Tidak terdapat taksonomi medis yang jelas pada dataset akhir ini membuat data tidak bisa dioperasikan oleh sistem rumah sakit lain (*non-interoperable*).

	hr	sbp	temp	sepsis	x1	x2	x3	y	x2_norm	f	pred
1	110	95	38.5	1	110	95	38.5	1	166,666,666,666,667	1	1
2	85	120	36.8	0	85	120	36.8	0	1	0	0
3	125	90	39.2	1	125	90	39.2	1	0	1	1
4	75	115	37.1	0	75	115	37.1	0	833,333,333,333,333	0	0
5	105	100	38.1	1	105	100	38.1	1	333,333,333,333,333	1	1

Gambar 2.3 Dataset *output* Tahap 1

3. **Tahap 2 (Commit Kedua):** Melakukan perbaikan pada skrip tersebut. Kode telah dioptimalkan menggunakan fungsi vektorisasi dari *library* dplyr agar lebih efisien. Selain itu, penamaan variabel telah diubah menggunakan standar rekam medis yang jelas, dan ditambah komentar analitik/medis pada setiap baris kodenya.

```
# Mengatur lokasi folder kerja
setwd("C:/Users/yuwan vira/OneDrive/Dokumen/BIG DATA")

# Memanggil library untuk manipulasi data yang efisien
library(dplyr)

# 1. IMPORT DATA
ehr_raw <- read.csv("data_final_beneran.csv")

# 2. PENYELARASAN NAMA VARIABEL & PEMBERSIHAN
# Alasan Klinis/Statistik: Mengubah nama variabel mentah yang ambigu (hr, sbp, temp)
# menjadi nama taksonomi medis baku.
# Standardisasi nomenklatur ini penting dalam EHR untuk memastikan interoperabilitas dan
# mencegah salah interpretasi fitur saat audit.
ehr_clean <- ehr_raw %>%
  rename(
    heart_rate = hr,
    systolic_bp = sbp,
    temperature = temp,
    is_sepsis = sepsis
  ) %>%
  # Alasan Medis: Menggunakan fungsi penghapusan baris kosong (listwise deletion).
  # Mengimputasi (menebak/mengisi) parameter medis akut yang hilang berisiko besar
  # mengaburkan profil hemodinamik pasien yang sesungguhnya dan memicu salah diagnosis.
  na.omit()
```

```

# 3. REKAYASA FITUR (FEATURE ENGINEERING)
ehr_processed <- ehr_clean %>%
  mutate(
    # Alasan Statistik: Normalisasi Min-Max pada tekanan darah sistolik agar skala variabel ini seragam.
    # Hal ini mencegah distorsi bobot koefisien oleh satuan ukur yang besar dan
    # mempercepat konvergensi algoritma regresi.
    sys_bp_norm = (systolic_bp - min(systolic_bp)) / (max(systolic_bp) - min(systolic_bp)),

    # Alasan Medis: Binarisasi suhu tubuh (cut-off > 38.0 C) didasarkan pada definisi klinis
    # demam dalam kriteria SIRS (Systemic Inflammatory Response Syndrome).
    # Demam merupakan tanda awal peradangan sistemik sebelum pasien jatuh ke syok septik.
    fever_sirs_flag = ifelse(temperature > 38.0, 1, 0)
  )

# 4. PEMODELAN KLINIS
# Alasan Statistik: Menggunakan regresi logistik (binomial) karena target variabel bersifat dikotomi
# (Sepsis: Ya/Tidak).
# Model ini menghasilkan interpretabilitas tinggi (berupa Odds Ratio) yang sangat krusial bagi klinisi.
sepsis_model <- glm(
  is_sepsis ~ heart_rate + sys_bp_norm + fever_sirs_flag,
  data = ehr_processed,
  family = binomial(link = "logit")
)

# 5. PREDIKSI & PENILAIAN RISIKO
# Alasan Medis: Threshold probabilitas ditingkatkan ke 0.65 (bukan 0.5 default) untuk meningkatkan spesifisitas.
# Alarm peringatan dini (early warning system) medis yang terlalu sensitif
# akan menyebabkan 'alarm fatigue' di ruang ICU.
ehr_final <- ehr_processed %>%
  mutate(
    sepsis_prob = predict(sepsis_model, type = "response"),
    high_risk_alert = ifelse(sepsis_prob > 0.65, 1, 0)
  )

# Menyimpan hasil akhir dengan nama yang lebih profesional
write.csv(ehr_final, "ehr_sepsis_predictions_clean.csv", row.names = FALSE)

```

Gambar 2.4 Skrip akhir yang telah dioptimasi dan dilengkapi rasionalisasi klinis.

Melalui perbaikan kode, wujud *output* dataset akhir kini menjadi jauh lebih terstruktur. Kolom yang awalnya ambigu berhasil dikembalikan ke nama baku (*heart_rate*, *systolic_bp*, *temperature*). Selain itu, terdapat penambahan fitur patofisiologis baru yang dihitung dengan fungsi **mutate()**, yaitu **fever_sirs_flag** (indikator demam berbasis kriteria medis SIRS dengan suhu > 38.0°C) dan fitur prediksi akhir **high_risk_alert**.

heart_rate	systolic_bp	temperature	is_sepsis	sys_bp_norm	fever_sirs_flag	sepsis_prob	high_risk_alert
110	95	38.5	1	166,666,666,666,667	1	999,999,999,978,567	1
85	120	36.8	0	1	0	2.14E+03	0
125	90	39.2	1	0	1	999,999,999,978,567	1
75	115	37.1	0	833,333,333,333,333	0	2.14E+03	0
105	100	38.1	1	333,333,333,333,333	1	999,999,999,978,567	1


Gambar 2.5 Dataset akhir yang menunjukkan hasil transformasi fitur klinis per pasien.

Berdasarkan Gambar 2.5, logika medis dari model telah bekerja dengan akurat:

- **Kasus Berisiko Tinggi:** Pada baris pertama, pasien masuk dengan kondisi *heart rate* 110 bpm dan suhu 38.5°C. Karena suhu > 38.0°C, sistem secara otomatis memberikan nilai 1 pada kolom **fever_sirs_flag** (indikator demam

klinis SIRS). Kombinasi hemodinamik ini memicu probabilitas sepsis yang tinggi sehingga kolom **high_risk_alert** bernilai 1.

- **Kasus Stabil:** Sebaliknya, pada baris kedua, pasien memiliki suhu normal (36.8°C) dan tekanan darah sistolik yang cukup baik (120 mmHg). Sistem dengan tepat memberikan flag demam 0 dan pasien tidak diklasifikasikan ke dalam peringatan risiko tinggi (**high_risk_alert** bernilai 0).



Gambar 2.6 Visualisasi proses binarisasi parameter suhu tubuh

Berdasarkan Gambar 2.6 dapat dilihat bahwa variabel suhu tubuh yang awalnya berupa data kontinu (histogram kiri) dipisahkan menggunakan batas ambang klinis (*threshold*) 38.0°C , yang ditandai dengan garis putus-putus merah. Proses binarisasi ini terbukti secara akurat membagi populasi pasien ke dalam dua kelompok yaitu : 2 pasien masuk dalam kategori normal (Status 0) dan 3 pasien masuk dalam indikasi demam SIRS (Status 1) pada diagram batang di sebelah kanan. Transformasi ini tidak hanya mengubah bentuk data secara matematis, melainkan berhasil mengekstraksi *insight* biologis menjadi indikator risiko diskret yang jauh lebih mudah dan akurat untuk diproses oleh algoritma klasifikasi *machine learning*.

4. **Tahap 3 (Dokumentasi README):** Membuat file README.md pada repositori Git. File README.md ini dibuat untuk memenuhi kriteria prinsip FAIR (*Findable, Accessible, Interoperable, Reusable*) dalam tata kelola data kesehatan. Di dalam dokumentasi ini memuat komponen sebagai berikut:

- **Spesifikasi Lingkungan & Versi Software:** Mendokumentasikan secara presisi versi perangkat lunak yang digunakan, yaitu R version 4.3.2 dan *library* dplyr

version 1.1.4, guna meminimalkan risiko kegagalan replikasi akibat perbedaan versi paket komputasi.

- Prinsip Kepatuhan FAIR: Menjabarkan secara eksplisit bagaimana repositori ini memenuhi empat pilar FAIR (ketersediaan data, aksesibilitas publik, interoperabilitas taksonomi medis baku, serta kesiapan kode untuk digunakan kembali oleh peneliti lain).
- Kamus Data (*Data Dictionary*): Menyediakan deskripsi metadata, tipe data, pemetaan transformasi variabel, hingga satuan klinis baku (seperti BPM, mmHg, dan °C) untuk variabel *input* maupun *output*.

Seluruh riwayat versi (*commit history*), skrip R, beserta perbandingan wujud dataset ini dapat ditinjau dan diaudit langsung melalui tautan repositori GitHub berikut:

<https://github.com/yuwaaaaan/Tugas-Tambahan-Big-Data.git>

Bagian 3: Protokol Aksesibilitas dan Privasi Data

1. Mekanisme Berbagi Data (Berdasarkan Tabel 1 Streiber et al.)

Untuk kasus penyebaran data yang tingkat sensitivitasnya sangat tinggi seperti data genomik internasional, pilihan mekanisme berbagi data yang paling tepat berdasarkan jurnal Streiber et al. adalah **Repositori Institusional Tertutup** (*Controlled-access / Closed Institutional Repository*). Hal ini dikarenakan data genomik bersifat sangat unik bagi setiap individu dan memiliki risiko kebocoran privasi yang fatal jika diretas atau disalahgunakan, sehingga tidak boleh disebarluaskan secara bebas ke publik. Melalui sistem repositori tertutup, peneliti eksternal yang membutuhkan data wajib mengajukan proposal resmi terlebih dahulu dan menyetujui *Data Use Agreement* (DUA). Institusi pengelola data kemudian akan menyeleksi dan memberikan izin akses hanya kepada pihak yang terverifikasi. Sistem ini memastikan kolaborasi riset antar negara tetap berjalan dengan baik tanpa mengorbankan privasi pasien.

2. Teknik Preservasi Privasi dalam Kode Analitis

Sebelum mengeksport data medis hasil olahan (misalnya menggunakan fungsi `write.csv` di R), terdapat dua teknik perlindungan privasi yang wajib disematkan ke dalam *pipeline* kode untuk memastikan identitas pasien tidak dapat dilacak kembali :

- **Masking (Pseudonimisasi):** Teknik ini digunakan untuk menyensor atau menghapus variabel identitas langsung (*Direct Identifiers*) seperti Nama Pasien, NIK, atau Nomor Rekam Medis. Praktik penulisan kodenya di R dilakukan dengan membuang kolom-kolom rentan tersebut sejak awal proses pembersihan data (misalnya menggunakan fungsi `select(-nama_pasien)` pada paket **dplyr**).
- **k-Anonymity:** Teknik ini berfokus untuk menyamarkan data *Quasi identifiers* (data penunjang yang jika dikombinasikan dapat membongkar identitas, seperti usia, jenis kelamin, atau kode pos daerah). Prinsip utamanya adalah memastikan data satu pasien terlihat sama dengan minimal $k-1$ pasien lainnya. Di dalam skrip kode, hal ini diimplementasikan dengan mengonversi nilai pasti menjadi sebuah kategori interval (*binning*). Sebagai contoh, alih-alih memasukkan data usia eksak "42 tahun", kode akan mengubahnya menjadi rentang "Kelompok Usia 40-50 Tahun".

Tabel 3.1 Perbandingan sebelum dan sesudah penerapan teknik *Masking* dan *k-Anonymity* pada data rekam medis.

Data Asli (Rentan Privasi)	Data Setelah Masking & k-Anonymity
Nama: Budi Santoso Usia: 42 Tahun Diagnosis: Sepsis	ID: PASIEN_001 (<i>Masking</i>) Usia: 40-50 Tahun (<i>k-Anonymity</i>) Diagnosis: Sepsis
Nama: Siti Aminah Usia: 48 Tahun Diagnosis: Sepsis	ID: PASIEN_002 (<i>Masking</i>) Usia: 40-50 Tahun (<i>k-Anonymity</i>) Diagnosis: Sepsis

Bagian 4: Penalaran Klinis (*Clinical Reasoning*) dan Interpretabilitas


1. Validasi Logika Medis (*Sanity Check* terhadap Patofisiologi)

Meskipun model Big Data memberikan skor probabilitas risiko sepsis yang tinggi, apabila kondisi klinis pasien di ranjang perawatan tampak stabil, klinisi tidak dapat hanya mengandalkan peringatan mesin tersebut. Langkah *sanity check* utama yang harus dilakukan adalah mengevaluasi tren kombinasi antar variabel, bukan sekadar melihat satu parameter tunggal yang memicu alarm.

Sebagai contoh, model mungkin memberikan peringatan bahaya karena mendeteksi lonjakan denyut jantung (takikardia). Secara patofisiologi, korelasi statistik ini harus divalidasi dengan memeriksa parameter penunjang seperti nilai *Mean Arterial Pressure* (MAP) atau hasil laboratorium laktat. Jika MAP terpantau normal dan tidak ada indikasi penumpukan laktat (hipoksia jaringan), maka lonjakan detak jantung tersebut kemungkinan besar hanyalah kompensasi fisiologis sekunder (misalnya akibat demam, kecemasan, atau pergerakan pasien), bukan fase awal dari syok septik. Korelasi yang ditemukan oleh mesin harus selalu diverifikasi dengan teori medis dasar untuk mencegah terjadinya *alarm fatigue* (kelelahan akibat peringatan palsu yang repetitif) di ruang ICU.

2. Interpretabilitas Model (Transparansi Fitur)

Di ranah perawatan kritis, dokter tidak akan mengadopsi model *black box* yang hanya memunculkan angka probabilitas tanpa dasar penalaran yang jelas. Untuk menjembatani hal ini, *output* model dirancang menggunakan pendekatan visualisasi SHAP Values. SHAP dipilih karena mampu menjelaskan kontribusi setiap fitur pada tingkat individu pasien (local interpretability), bukan hanya pada tingkat populasi secara umum.



Gambar 4.1 Simulasi visualisasi kontribusi fitur klinis menggunakan pendekatan SHAP Value.

Selain visualisasi grafik pada Gambar 4.1, *output* peringatan dini juga ditranslasikan menjadi narasi otomatis bagi klinisi, seperti:

"Peringatan: Risiko Sepsis 80%. Risiko ini didorong secara signifikan oleh Suhu > 38.0°C (+25%) dan Detak Jantung > 110 bpm (+15%), meskipun tekanan darah sistolik saat ini masih memberikan kompensasi penahanan risiko (-5%)."

Transparansi fitur ini sangat krusial dalam *clinical reasoning* karena memungkinkan dokter untuk memverifikasi apakah bobot yang diberikan algoritma masuk akal secara medis. Dengan demikian, dokter tetap memegang otoritas penuh atas keputusan klinis dan terhindar dari potensi malpraktik akibat kesalahan interpretasi mesin.

3. Evaluasi Ground Truth (Bias Data EHR vs Realitas Klinis)

Akurasi model komputasi sering kali menurun drastis ketika diimplementasikan secara langsung karena algoritma menyerap bias operasional yang inheren dalam Rekam Medis Elektronik (EHR). Data EHR sangat rentan untuk tidak mencerminkan kondisi riil pasien (*bedside reality*) akibat beberapa faktor berikut:

- **Upcoding Administratif:** Staf administrasi rumah sakit sering kali memasukkan kode diagnosis (ICD) yang terkesan lebih parah atau akut dibandingkan kondisi aslinya. Hal ini umumnya didorong oleh tekanan birokrasi untuk memaksimalkan pencairan klaim asuransi kesehatan. Akibatnya, mesin belajar dari label data yang secara artifisial "terlihat lebih sakit" daripada realitasnya.
- **Informative Missingness (Kelangkaan Data Informatif):** Pada jam observasi tertentu, jika dokter melihat pasien dalam keadaan stabil, dokter cenderung memutuskan untuk tidak meresepkan tes laboratorium lanjutan yang tidak perlu. Di dalam sistem EHR, ketiadaan tes ini akan terekam sebagai nilai kosong (*missing values*). Algoritma komputasi dapat dengan keliru menafsirkan pola kekosongan data ini sebagai sebuah anomali atau risiko, padahal secara klinis, hilangnya data tersebut justru merupakan proksi yang menunjukkan bahwa kondisi pasien sedang baik-baik saja menurut justifikasi dokter jaga.
- **Data Entry Error (Kesalahan Input Manual):** Kesalahan pengetikan (tipografi) oleh tenaga kesehatan saat memindahkan data dari monitor fisik ke sistem EHR adalah hal yang sangat lumrah. Sebagai contoh, tekanan darah sistolik 120 mmHg sering kali salah diketik menjadi 210 mmHg. Algoritma komputasi akan menelan data ini mentah-mentah dan memproses angka "210" tersebut sebagai krisis hipertensi ekstrem, padahal dalam realitas klinisnya di ranjang perawatan (*bedside reality*), pasien tersebut dalam keadaan sangat stabil. Kesalahan pencatatan ini membuat *ground truth* di data digital menjadi tidak sinkron dengan kondisi fisiologis asli pasien.